

Projet ML — Prédiction du prix des billets d'avion

XGBoost | R2 = 0.987 | MAE = 1 410 Rs

1. Problématique

L'objectif est de prédire le prix d'un billet d'avion à partir de ses caractéristiques (compagnie, escales, classe, durée, jours restants...). Le dataset contient 300 153 vols indiens avec 10 variables.

2. Analyse exploratoire (EDA)

- **Distribution asymétrique** : la majorité des billets < 20 000 Rs, skewness = 1.06, présence d'outliers.
- **Variables clés** : la classe du vol, la compagnie et les escales ont l'impact le plus significatif sur le prix.
- **Corrélations** : duration +0.20 avec le prix, days_left -0.09 (plus on réserve tard, plus c'est cher).

3. Pre-processing

- **Log transform** : $y = \text{np.log1p}(\text{price})$ pour corriger l'asymétrie — retransformation avec $\text{np.expml}()$ après prédiction.
- **Split** : 80% train / 20% test avant tout encodage (éviter le data leakage).
- **Encodage** : LabelEncoder sur stops et class, OneHotEncoder sur les 5 variables nominales.
- **Normalisation** : StandardScaler applique après encodage.

4. Comparaison des modèles

Modele	MAE	RMSE	R2	Temps
Random Forest	1760.46	3414.34	0.98	385.47
DT	1158.26	3492.31	0.98	56.56
XGBoost	2093.53	3821.94	0.97	2.78
Gradient Boosting	2971.89	5119.86	0.95	37.59
AdaBoost	3589.14	5896.95	0.93	19.50
LSVR	4577.65	7686.60	0.89	69.48
Ridge	4778.51	8143.81	0.87	0.24
Linear Regression	4778.48	8143.73	0.87	0.30
ENet	13316.82	20713.85	0.18	0.19
Lasso	16614.70	24704.57	-0.17	0.21

Les modèles linéaires plafonnent à $R^2=0.91$ — la relation est clairement non-linéaire. Decision Tree surfit. XGBoost est 150x plus rapide que Random Forest pour le même R^2 .

5. Cross Validation

Modele	R2 CV	Std	Verdict
Random Forest	0.979	0.000	Stable
XGBoost	0.976	0.000	Stable
Gradient Boosting	0.952	0.001	Stable

Ecart-type quasi nul pour les 3 modèles — aucune instabilité, les scores sont fiables.

6. Tuning

Modele	R2 avant	R2 apres	Gain
XGBoost	0.976	0.986	+0.010
Random Forest	0.979	0.977	-0.002
Gradient Boosting	0.952	0.976	+0.024

XGBoost bénéficie le plus du tuning. Random Forest etait deja a son plafond.

7. Modele final — XGBoost tuné

Set	MAE	RMSE	R2
Train	1 255 Rs	2 298 Rs	0.990
Test	1 410 Rs	2 619 Rs	0.987
Delta	155 Rs	321 Rs	0.003

Delta R2 = 0.003 — aucun sur-apprentissage. Le modele explique 98.7% de la variance des prix.

8. Pipeline & Déploiement

- **Pipeline sklearn** : OrdinalEncoder + OneHotEncoder + StandardScaler + XGBoost dans un seul objet .pkl.
- **Streamlit** : Application web avec 2 modes — saisie manuelle des parametres ou upload CSV pour predictions en masse.